



# Predizendo uma variável por outra

## - Regressão Linear - Parte 2

# Aula	44
<input checked="" type="checkbox"/> Preparada	<input checked="" type="checkbox"/>
<input checked="" type="checkbox"/> Revisada	<input checked="" type="checkbox"/>
<input checked="" type="checkbox"/> Lecionada	<input checked="" type="checkbox"/>

### ▼ Propriedades da equação do Método dos Mínimos Quadrados

A equação de reta obtida pelo Método dos Mínimos Quadrados apresenta tanto resíduos positivos quanto resíduos negativos.

A equação de reta obtida pelo Método dos Mínimos Quadrados **zera a soma** dos resíduos.

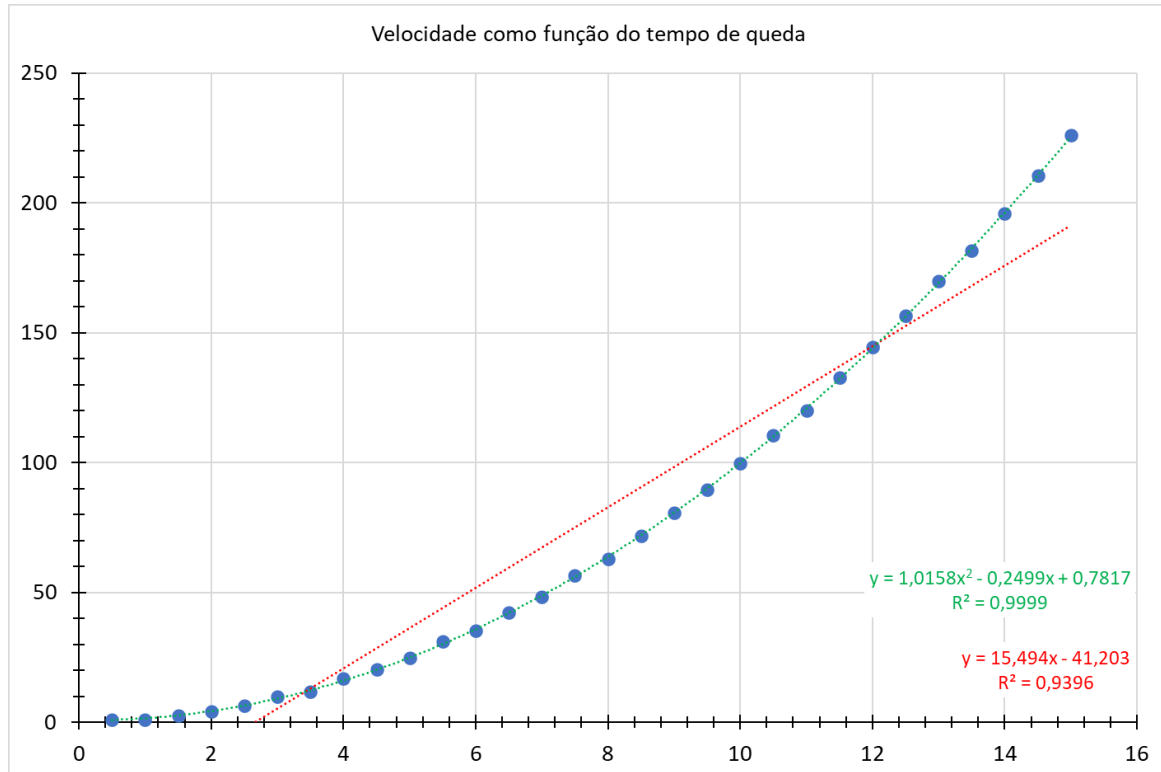
A equação de reta obtida pelo Método dos Mínimos Quadrados **minimiza o soma dos quadrados** dos resíduos.

A equação de reta obtida pelo Método dos Mínimos Quadrados **passa pelo ponto médio de coordenadas**  $(\bar{x}, \bar{y})$ .

A equação de reta obtida pelo Método dos Mínimos Quadrados **pode ser generalizada para dar origem à Regressão Linear Múltipla:**

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + (...) + \beta_n x_n$$

A equação de reta obtida pelo Método dos Mínimos Quadrados **é linear nos seus coeficientes  $\beta_i$** . Podemos tratar de relações não lineares com as variáveis  $x_i$ .



## ▼ Fórmula do Método dos Mínimos Quadrados

Lembrando que estamos falando da equação de reta **de 1 variável preditora**:

$$\hat{y} = f(x) = \beta_0 + \beta_1 x$$

▼ A inclinação  $\beta_1$  pode ser calculada com

$$\beta_1 = r_{(x,y)} \frac{s_y}{s_x}$$

Ou seja, a inclinação tem a ver com a correlação e com os desvios padrão de  $x$  e  $y$ .

Na prática, os softwares não dependem do cálculo da correlação nem do desvio padrão de  $y$ , podendo calcular mais

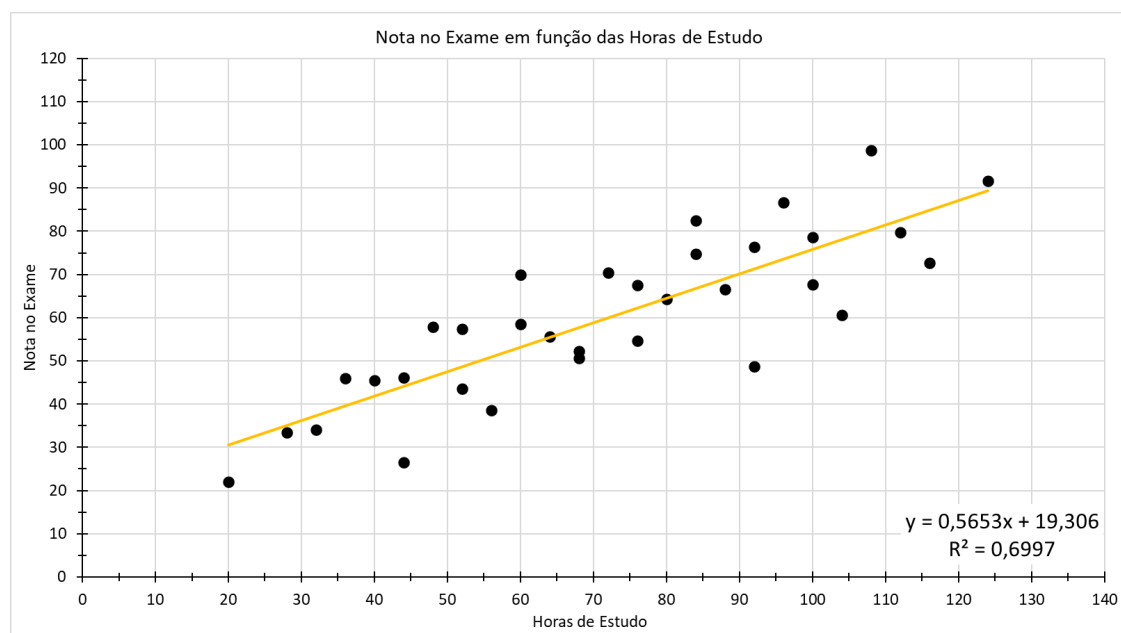
rapidamente a inclinação  $\beta_1$  por

$$\beta_1 = \frac{1}{(n-1)s_x^2} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

▼ A partir da inclinação  $\beta_1$  podemos calcular o intercepto  $\beta_0$  com

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

▼ Do exemplo anterior



$$\beta_0 = 19,306$$

$$\beta_1 = 0,5653$$

$$\hat{y} = 19,306 + 0,5653x$$

▼ **Afinal, e o  $R^2$ ?**

▼ Primeira interpretação

No caso específico de uma equação de reta,  $R^2$  é exatamente o quadrado da correlação entre x e y. Ou seja.

$$R^2 = r_{(x,y)}^2$$


Inclusive o quadrado na notação vem exatamente daí. Vemos pela fórmula que o  $R^2$  varia entre 0 e 1 (ou entre 0% e 100%).

## ▼ Segunda interpretação

Para modelos em geral, o  $R^2$  é uma função entre a soma de quadrados de resíduos do modelo e a soma de quadrados de distância da média de  $y$  dada por

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- A fórmula acima foi colorida para você reparar na distância entre os dados e a média de  $y$  em vermelho e na distância entre os dados e o modelo de  $y$  em azul.



## ▼ Importantíssimo:

O  $R^2$  é uma medida de redução do erro que se tem ao usar o modelo ao invés de usar a média. No exemplo acima, o  $R^2$  de 0,6997 significa que erramos 70% menos usando o modelo para prever  $y$  do que se fizéssemos a previsão de  $y$  pela média.

## ▼ Curiosidade:

Se você propuser no exemplo do gráfico acima uma equação de reta decrescente (enquanto a associação dos dados é

positiva), é possível que a conta proposta na segunda interpretação tenha um resultado negativo...

## ▼ Outros diagnósticos em modelos de regressão:

### ▼ **MAE** (*Mean Absolute Error* [Erro Absoluto Médio])

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

### ▼ **MSE** (*Mean Squared Error* [Erro Quadrático Médio])

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

### ▼ **RMSE** (*Root Mean Squared Error* [Raiz do Erro Quadrático Médio])

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

## ▼ Então... Quais destes indicadores vamos usar?

O **MSE** é expresso na unidade ao quadrado.

Já o **MAE** e o **RMSE** estão na mesma unidade que o dado original, então usamos os dois!

### ▼ Faz sentido?

A comparação entre o **MAE** e o **RMSE** vai nos mostrar quantos valores extremos temos nos erros do modelo em que estamos medindo estes indicadores.